

AUDIT COMPLET

Polymarket Trading Bot

Date : 2026-04-01

Perspective : Senior Quantitative Researcher

Mode : Read-only | Confidentiel

*Cet audit couvre l'ensemble du codebase : core/, pipeline/, infra/, execution/, tests/.
Il identifie les bugs critiques, les risques de perte d'argent, et propose une roadmap priorisee.*

EXECUTIVE SUMMARY

VERDICT : LE BOT N'EST PAS PRET POUR LE LIVE TRADING

L'architecture est saine et le concept d'edge informationnel via LLM sur marches de niche est viable. Cependant, 8 bugs critiques (Tier 1) peuvent et vont perdre de l'argent en live. En paper trading, les resultats sont biaises a la hausse a cause de : frais non deduits des wins, Kelly avec mauvaise probabilite, et max_pct plus agressif qu'en live.

Bugs critiques identifies : 8

Warnings : 9

Temps estime pour fixes Tier 1 : ~10 heures

Recommandation : corriger les 8 bugs Tier 1, puis tourner 200+ trades paper avec un Brier score < 0.25 et un edge net positif apres frais. Considerer le passage en live avec \$100 (pas \$500) apres validation statistique.

1. ALPHA & EDGE ANALYSIS

Scoring Pipeline (scorer.py)

OK

Prompts segmentes par categorie, second opinion adversariale, validation Pydantic

CRITICAL

Formule de frais fausse (scorer.py:340)

Le code actuel traite le fee Polymarket (2%) comme une deduction plate sur le gap de probabilite. Or Polymarket charge 2% sur le PROFIT, pas sur la probabilite.

```
# ACTUEL (faux)
edge_yes = prob - price - 0.02

# CORRECT
ev = agent_prob * (1 - market_price) * 0.98
    - (1 - agent_prob) * market_price
```

Impact : sous-estime l'edge de 15-20% a prix moyens. La direction de l'erreur varie avec le niveau de prix. Le filtre de trading est calibre sur une quantite fantome.

CRITICAL

Divergence ne bloque pas les trades (scorer.py:393-430)

Quand les deux opinions divergent de >0.15, le bot met data_quality='low' mais ne touche pas confidence. Le flag tradeable depend uniquement de edge_net et confidence. data_quality n'est verifie NULLE PART dans la gate logic. Un marche avec opinion1=0.70 et opinion2=0.50 trade a 0.70 avec confidence=8.

Signaux manquants

- Pas de signal de microstructure (spread, profondeur carnet, imbalance)
- Pas de momentum/mean-reversion sur le prix du marche
- Pas de detection de 'smart money' (grands ordres recents)
- Pas de ponderation temporelle des news (recentes vs anciennes = meme poids)

2. RISK MANAGEMENT

Kelly Sizing

OK Formule $f^* = (b \cdot p - q) / b$ algebriquement correcte

OK Quarter-Kelly (0.25) appropriée pour \$500 bankroll

WARNING Kelly utilise la mauvaise probabilité

$p = \text{market_price} + \text{edge_net}$, mais edge_net a déjà eu les frais deduits. Donc $p = \text{agent_prob} - \text{fee}$, pas agent_prob . L'undersizing est conservateur (~0.8% bankroll) mais ce n'est pas du vrai quarter-Kelly.

WARNING Paper vs Live divergent

Paper $\text{max_pct}=0.10$, Live $\text{max_pct}=0.08$. Paper est 25% plus agressif. Les resultats paper ne sont pas extrapolables au live.

Correlation entre positions

CRITICAL `check_category_exposure()` est du DEAD CODE (`sizing.py:59-70`)

La fonction existe, est testée, mais n'est jamais appelée dans `compute_position_size()`. Le bot PEUT et VA empiler des positions corrélées (3 trades NBA, 3 trades elections US) qui résolvent toutes dans la même direction.

Circuit Breaker

WARNING Ne regarde que les trades résolus, pas les positions ouvertes

Le circuit breaker = PnL résolu sur 7 jours avec $\text{max_drawdown}=20\%$. 5 positions peuvent être ouvertes et perdre simultanément pendant des jours avant qu'un seul marche ne résolve. Pas de stop intra-cycle, pas de mark-to-market.

Avec 5 positions à 8% chacune = 40% exposure. Drawdown théorique de \$200 sur \$500 (40%) avant que le circuit breaker ne se déclenche.

Probabilité de ruine

Avec quarter-Kelly, le log-growth rate est positif (0.002-0.009/trade). Pas de ruine théorique SI les positions sont decorrélées. Mais sans contrôle de corrélation, une série de 5 pertes corrélées = -40% instantané.

CRITICAL `portfolio_health_check()` est DEAD CODE (`portfolio.py:123`)

Défini mais jamais appelé depuis l'orchestrateur. La gate composite pre-cycle n'existe pas.

3. EXECUTION & MARKET MICROSTRUCTURE

OK Limit orders only - structurellement impossible de passer un market order

OK `compute_limit_price()` est une pure function testable

CRITICAL `track_order_fill()` n'est jamais appele (orchestrator.py:183-188)

`place_limit_order()` est suivi immediatement par `record_fill()` avec le cout INTENTIONNEL, pas le cout REEL. Si l'ordre est partiellement fill (60%) et le reste cancel apres timeout, la DB enregistre 100%. Position size, risk calc et PnL sont faux pour ce trade.

WARNING Pas de verification de profondeur du carnet

Un ordre de 100 shares a \$0.555 sur un marche illiquide se fait partiellement fill silencieusement. Aucun check de liquidite avant le sizing.

WARNING Magic numbers hors config

`AGGRESSIVE_OFFSET = 0.005` et `MAX_SLIPPAGE = 0.02` dans `clob.py:18-19`. `max_exposure_pct=0.40`, `lookback_days=7`, `max_drawdown=0.20` dans `sizing.py`. Tous violent la regle 'no magic numbers outside infra/config.py'.

4. DATA PIPELINE

Fetcher (fetcher.py)

OK Toutes les requetes HTTP wrappees en try/except avec fallback gracieux

OK Cache TTL 5min pour les marches

CRITICAL Config override bypass (fetcher.py:30-31)

```
_VOLUME_MAX_OVERRIDE = 500_000 # ignore config.py (50k)
_DAYS_MAX_OVERRIDE = 90          # ignore config.py (30j)
```

infra/config.py affiche des valeurs qui ne sont JAMAIS utilisees. Quiconque modifie config.py pense changer les filtres alors que rien ne change.

WARNING Partial page failure perd toutes les donnees

Si page 0 retourne 100 marches mais page 1 fail, les 100 marches sont jetes. Le cache n'est pas peuple et le cycle suivant retente de zero.

News Enrichment (news.py)

OK Perplexity + RSS en parallele via ThreadPoolExecutor, timeout 15s

WARNING Pas de cache news - cout inutile ~\$0.30/heure

Meme question scoree dans les cycles 1 et 2 = 2 appels Perplexity identiques. Un cache TTL keye sur le hash de la question eliminerait les appels redondants.

WARNING Rate limiting inverse (orchestrator.py:85-91)

Le time.sleep fire APRES l'appel Perplexity, pas avant le suivant. Les appels back-to-back ont zero separation deliberee.

5. CALIBRATION & BACKTESTING

Calibration (calibration.py)

WARNING Aucun minimum de sample size par bucket

Avec ~20 trades/semaine, il faudra des mois avant d'avoir des buckets statistiquement significatifs ($n > 30$ par bucket pour CI à 95%). Pas de Brier score, pas de confidence intervals, pas de test de significativité statistique.

Backtesting

CRITICAL Il n'y a pas de backtest framework

Sans backtest :

- Impossible de distinguer skill vs luck
- Impossible de calibrer les paramètres
- Impossible de mesurer le Sharpe ratio
- Pas de stress-test sur les scénarios extrêmes

Mesure de profitabilité

Le seul indicateur est le paper PnL - qui est BIAISE À LA HAUSSE (pas de fee sur les wins, mauvaise Kelly). Pas de benchmark, pas de hit rate tracking, pas de edge decay analysis.

6. ARCHITECTURE & ROBUSTNESS

Single Points of Failure

Composant	Failure Mode	Handling	Status
Claude API	Timeout/down	try/except, cycle skip	OK
Gamma API	Down	Returns [], alert Telegram	OK
Perplexity	Down	Returns "", trade sans news	OK
CLOB	Down	OrderResult(error)	OK
SQLite	Corruption	PAS DE BACKUP AUTO	CRITIQUE
Scheduler	OOM/crash	Mort silencieuse, pas de heartbeat	HIGH

Idempotency

WARNING Non garantie

- Crash entre place_limit_order() et record_fill() = ordre on-chain sans trace DB
- cleanup_duplicate_trades() existe en CLI = preuve que des duplicatas ont deja eu lieu
- cancel_stale_orders() nettoie apres 60min mais pas de reconciliation

APScheduler Overlap

CRITICAL Pas de max_instances=1 (scheduler.py:54-61)

Si un cycle depasse 900s, le scheduler lance un second cycle en parallele. Deux cycles concurrents peuvent scanner les memes marches et placer des ordres en double.

Database

WARNING Zero indexes - full table scan a chaque cycle

WARNING Pas de WAL mode - deadlock si resolver + scheduler concurrent

WARNING FK non enforcees - PRAGMA foreign_keys = ON jamais execute

WARNING INITIAL_BANKROLL_USDC = 100.0 hardcoded

7. COMPETITIVE EDGE ASSESSMENT

Ce bot vs le marche

Dimension	Ce bot	Traders pro
Signal	Claude + Perplexity + RSS	Modeles custom + data proprio
Microstructure	Aucune	Spread capture, OB signals
Latence	~5-10min/cycle	Sub-seconde
Risk mgmt	Quarter-Kelly, no correl	Portfolio VaR, stress tests
Calibration	N/A (trop peu de data)	Brier score, calib curves
Fill quality	No confirmation	Fill-or-kill, partial fills

Edge structurel du bot

- Informational edge sur les niches : Claude peut synthetiser des news obscures que les market makers ne surveillent pas. C'est le seul vrai edge et il est reel sur les marches a faible volume.
- Discipline : pas d'emotion, trades systematiques.

Ce qui manque pour etre 'systematic'

- Fill confirmation et reconciliation
- Controle de correlation entre positions
- Backtest framework avec donnees historiques
- Monitoring en temps reel (dashboard + alertes)
- P&L tracking correct (avec frais)
- Position-level et portfolio-level risk limits

8. PRIORITIZED ROADMAP

TIER 1 - CRITICAL FIXES (font perdre de l'argent)

#	Fix	Effort	Impact
1	Corriger formule de frais (scorer.py + resolver.py)	2h	Edge + PnL faux partout
2	Wirer track_order_fill() - confirmer fills	4h	Phantom positions
3	Appeler check_category_exposure()	30m	5 trades correles = ruine
4	Appeler portfolio_health_check()	30m	Dead code critique
5	max_instances=1 dans APScheduler	10m	Trades dupliques
6	INITIAL_BANKROLL_USDC en env var	15m	Ordres 5x faux au deploy
7	log_trade + update_bankroll atomique	1h	Paper equity biaisee
8	Enforcement du divergence gate	1h	Bypass safety check

TIER 2 - HIGH IMPACT (augmentent l'edge)

#	Fix	Effort	Impact
9	Magic numbers dans config.py	2h	Config source of truth
10	Supprimer fetcher overrides	30m	Config.py fiable
11	DB indexes (status, date, market)	30m	Performance
12	WAL mode + FK pragma	15m	Concurrence + integrite
13	Aligner paper_kelly avec live_kelly	1h	Paper = proxy fiable
14	Cache news TTL	2h	-\$7/jour Perplexity
15	Orderbook depth check avant sizing	4h	Eviter illiquidite
16	Intra-cycle drawdown stop	8h	Protection temps reel
17	Heartbeat Telegram a chaque cycle	30m	Detection mort silencieuse

TIER 3 - NICE TO HAVE (ameliorations incrementales)

#	Fix	Effort	Impact
18	Backtest framework avec donnees historiques	2-3s	Mesure du vrai alpha
19	Brier score + calibration CI par bucket	1s	Scoring auto-amelioration
20	Edge decay analysis	1s	Timing optimal
21	Partial fill handling correct	4h	Accuracy du PnL
22	DB backup automatique (daily cron)	1h	Recovery
23	Fix 5 test files (deps manquantes)	2h	Couverture réelle
24	Reconciliation on-chain au restart	8h	Pas de phantom trades

Dashboard PnL en temps reel

1s

Monitoring

VERDICT FINAL

LE BOT N'EST PAS PRET POUR LE LIVE TRADING

L'architecture est saine, le concept d'edge informationnel via LLM sur marches de niche est viable, mais les 8 bugs Tier 1 (fee formula, fill tracking, correlation control, scheduler overlap) peuvent et vont perdre de l'argent.

En paper trading, les resultats sont biaises a la hausse a cause de : frais non deduits des wins, Kelly avec mauvaise probabilite, et max_pct plus agressif qu'en live.

Estimation du temps pour Tier 1 : ~10 heures de developpement.

Plan de passage en live :

- Corriger les 8 bugs Tier 1 (~10h)
- Tourner 200+ trades paper avec metriques corrigees
- Valider : Brier score < 0.25 , edge net positif apres frais
- Passage live avec \$100 (pas \$500)
- Augmenter progressivement apres 100 trades live profitables

Rapport genere le 2026-04-01 | Audit read-only | Confidential